

Master 1 Modélisation Statistique Besançon: cours Modèles Linéaires

TP 3 bis

Validation croisée, Résidus studentisés par validation croisée, points levier, distance de Cook: implémentation "à la main"

20 février 2025

Vous devez rendre votre travail sous la forme d'un fichier .pdf ou .Rmd avant le 24 mars, 12h00. Ce travail sera réalisé individuellement et noté.

Le but principal de ce TP est d'implémenter la validation croisée "à la main" et la tester sur un gros jeu de données. Le deuxième but du TP est d'implémenter les fonctions vues en TP3 qui sont basées principalement sur le principe de validation croisée "leave-one-out" vue en cours (modèle basé sur l'échantillon privé d'une observation) et les tester également sur un gros jeu de données. Vous aurez besoin pour cela des propriétés vues dans le cours 2 et le TD 2.

Il faudra pour cela que les programmes soient efficaces (rapides en temps de calcul et peu gourmands en mémoire utilisée), donc il faudra réfléchir à éviter certaines opérations gourmandes comme par exemple les boucles, les opérations matricielles (même si c'est par des matrices creuses) ou le stockage des gros objets. Pour tester le temps de calcul de vos fonctions, vous pouvez utiliser la fonction `system.time`.

Vos programmes doivent être visibles dans vos rendus de TP.

partie A : Données d'électricité Nous considérons les données de consommation électrique de $n = 6291$ entreprises françaises mesurées toutes les 30 minutes pendant deux semaines par des compteurs Linky. Ces mesures sont contenues dans l'objet `smart278co.Rdata` (attention, ce jeu de données est volumineux!) : en ligne, on a les entreprises et par colonne, les mesures d'électricité (variables $X_{i,j}$). On charge les données avec la fonction `load` de la façon suivante (vous pouvez utiliser également les commandes apprises en R avancé) :

```
##il faudra faire attention a changer le chemin!
> load("/Users/cameliagoga/Documents/SmartData - CER/smart278co.Rdata")
> View(smart.278co)
> dim(smart.278co)
[1] 6291 672
##representation d'une courbe d'électricité
> plot(smart.278co[100,],type ="l")
```

L'objectif de cette partie est d'implémenter la validation croisée "leave-one-out" vue en cours.

1. Les données d'électricité enregistrées pendant la première semaine, plus la variable constante, constitueront nos variables explicatives d'un modèle linéaire pour expli-

quer la consommation électrique du lundi (c'est à dire la somme des consommations enregistrées à tous les instants du lundi) de la deuxième semaine (le vecteur $\mathbf{y}$). Réalisez ces extractions de variables explicatives et de $\mathbf{y}$ à partir du jeu de données initial (attention au format des données) et donner ensuite l'ajustement $\hat{\mathbf{y}}$ de $\mathbf{y}$ à partir de ce modèle ; calculez également le vecteur des résidus d'estimations $\boldsymbol{\varepsilon} = (\varepsilon_i)_{i=1}^n = \mathbf{y} - \hat{\mathbf{y}}$. Vous pouvez utiliser dans cette partie la fonction `lm` pour calculer vos valeurs ajustées ou résidus d'estimation.

2. On souhaite maintenant calculer, pour tout $i = 1, \dots, n$, les résidus de prévision calculés par validation croisée "leave-one-out".
 - (a) Calculer les résidus de prévision (basés sur des modèles privés d'une observation) $\hat{\varepsilon}_{(i)} = y_i - \hat{y}_{(i)}$, $i = 1, \dots, n$ est la prédiction de y_i calculée à partir du modèle basé sur l'échantillon privé de l'observation i . Cela revient à poser n modèles, voir le cours et le TD pour la partie théorique. Attention à la façon dont vous implémentez vos programmes ! Vous pouvez utiliser de nouveau la fonction `lm`.
 - (b) Calculer maintenant $\hat{\varepsilon}_i / (1 - h_{ii})$, $i = 1, \dots, n$ où $\hat{\varepsilon}_i$ est le résidu d'estimation de y_i à partir du modèle global (basé sur le n observations) et h_{ii} est l'élément qui se trouve sur i ème place de la diagonale de $\mathbf{P}_\mathbf{X} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$. Vous pouvez de nouveau utiliser dans cette partie la fonction implémentée en R pour calculer les quantités h_{ii} .
 - (c) Comparer le vecteur $(\hat{\varepsilon}_{(i)})_{i=1}^n$ avec le vecteur $(\frac{\hat{\varepsilon}_i}{1-h_{ii}})_{i=1}^n$ (vous avez vu dans la correction du TP1 comment comparer les résultats de deux vecteurs).
3. Conclure.
4. Comme futur data scientist, est-ce que vous êtes d'accord avec cette modélisation ? Justifier votre réponse.

Partie B Dans cette partie, vous allez programmer "à la main" plusieurs fonctions implémentées en R et vues en TP3, comme par exemple la fonction `lm` et vous n'avez donc pas le droit de les utiliser. Par contre, vous devez comparer vos résultats avec les résultats obtenus avec les fonctions de R.

On considère $\mathbf{X}$ la matrice des variables explicatives de dimension $p + 1$ (avec la constante).

1. On commence par construire la matrice "hat"

$$\mathbf{P}_\mathbf{X} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top = (h_{ij})_{i,j=1}^n$$

à partir uniquement de $\mathbf{X}$. Donnez l'implémentation en R pour obtenir $\mathbf{P}_\mathbf{X}$ (pensez à utiliser les fonctions vues en TP pour calculer de façon rapide cette matrice). En déduire ensuite les éléments diagonaux h_{ii} , $i = 1, \dots, n$. Stocker ces éléments dans un vecteur $\mathbf{h} = (h_{ii})_{i=1}^n$ et comparez vos résultats avec ceux obtenus avec la fonction de R. Représentez ensuite graphiquement h_{ii} sur le jeu données de la partie A. Dans quelle analyse sont utiles ces quantités ?

2. A partir de $\mathbf{P}_\mathbf{X}$, déduisez le vecteur des valeurs ajustées $\hat{\mathbf{y}}$ (sans passer par $\hat{\boldsymbol{\beta}}$) et le vecteur des résidus estimés, $\hat{\boldsymbol{\varepsilon}} = \mathbf{y} - \hat{\mathbf{y}}$. Comparez vos résultats avec ceux obtenus avec la fonction de R.
3. On considère maintenant les résidus par validation croisée : $\hat{\varepsilon}_{(i)} = y_i - \hat{y}_{(i)}$. En utilisant le résultat de la feuille 2 de TD (voir aussi la partie A), donnez une méthode simple pour calculer sous R ces résidus $\hat{\varepsilon}_{(i)}$, $i = 1, \dots, n$.

4. En utilisant l'exercice 4 de la feuille 2 de TD, donnez une implémentation rapide pour calculer les distances de Cook $C_i, i = 1, \dots, n$. Comparez vos résultats avec ceux obtenus avec la fonction de R.
5. On souhaite maintenant calculer les résidus studentisés par validation croisée t_i^* :

$$t_i^* = \frac{\hat{\varepsilon}_i}{\hat{\sigma}_{(i)} \sqrt{1 - h_{ii}}}, \quad i = 1, \dots, n.$$

Nous avons besoin pour cela de calculer une estimation $\hat{\sigma}_{(i)}$ de σ basée sur l'échantillon privé de l'observation i . L'estimateur de $\hat{\sigma}_{(i)}^2$ est

$$\hat{\sigma}_{(i)}^2 = \frac{\sum_{j=1, j \neq i}^n \hat{\varepsilon}_{j(i)}^2}{n - 1 - (p + 1)}$$

où

$$\hat{\varepsilon}_{j(i)} = y_j - \hat{y}_{j(i)}$$

avec $\hat{y}_{j(i)} = \mathbf{x}_j^\top \hat{\boldsymbol{\beta}}_{(i)}$ la valeur ajustée de $y_j, j \neq i$ à partir du modèle construit sur l'échantillon privé de l'observation i . Si $j = i$, on obtient la valeur prédite de y_i donnée par $\hat{y}_{i(i)} = \hat{y}_{(i)} = \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{(i)}$.

L'objectif est de trouver une forme de $\hat{\sigma}_{(i)}^2$ qui s'exprime par rapport au modèle construit sur l'échantillon total de n observations, cela évitera faire n modèles. Pour répondre à cette question, voici ci-dessous deux points qui peuvent vous aider :

- (a) En utilisant l'exercice 4 de la feuille 2 de TD, montrer que les résidus $\hat{\varepsilon}_{j(i)}$ peuvent s'écrire par rapport aux résidus $\hat{\varepsilon}_i, i = 1, \dots, n$ comme suit :

$$\begin{aligned} \hat{\varepsilon}_{j(i)} &= \hat{\varepsilon}_j + \frac{h_{ij}}{1 - h_{ii}} \hat{\varepsilon}_i, \quad \text{pour } j \neq i \\ \hat{\varepsilon}_{i(i)} &= \frac{1}{1 - h_{ii}} \hat{\varepsilon}_i \quad \text{pour } j = i \end{aligned}$$

- (b) Proposez une fonction pour calculer $\hat{\sigma}_{(i)}, i = 1, \dots, n$ et déduisez ensuite t_i^* et comparez vos résultats avec ceux obtenus avec la fonction de R.